CENG 306 Biçimsel Diller ve Otomatlar Formal Languages and Automata

DETERMINISM and PARSING

Konular

- Determinism and Parsing
- Top-Down Parsing
- Bottom-Up Parsing

- Context-free diller programlama dillerinin syntax analizinde yoğun bir şekilde kullanılmaktadır.
- Programlama dili için geliştirilmiş bir compiler, bir parser oluşturmak zorundadır.
- Parser girilen bir string'in ilgili dile ait olup olmadığını belirler. Dile aitse o string icin bir parse tree oluşturur.
- Compiler daha sonra parse tree'yi assembly dili gibi temel bir dildeki programa dönüştürür.
- Compiler icin parser oluşturmada en başarılı sonuçlar pushdown automata ile alınmaktadır.
- Ancak PDA'lar yapısı gereği nondeterministic'tir ve deterministic olarak çalıştırılması zorunludur.

- Bir pushdown automaton deterministic'tir (DPDA) eğer herbir configuration için kendisini izleyen sadece bir configuration varsa.
- Eğer biri diğerinin prefix'i (öneki) ise iki katar consistent (tutarlı) dır,

- iki transition relation ((p, a, β), (q, y)) ve ((p, a', β'), (q', y')) compatible'dır (uyumludur) eğer <u>a ve a' ile ve aynı zamanda β ve β' ile consistent</u> ise yani her iki geçişin de aynı anda kabul edildiği bir durum varsa.
- !!! Eğer M PDA'sı deterministic ise iki farklı compatible geçiş olamaz.

Örnek: $L = \{wcw^R : w \in \{a, b\}^*\}$ dilini kabul eden aşağıdaki PDA deterministic'tir

$$M = (K, \Sigma, \Gamma, \Delta, s, F), K = \{s, f\}, \Sigma = \{a, b, c\}, \Gamma = \{a, b\}, F = \{f\}$$

 Δ toplam 5 adet geçiş ilişkisine sahip olsun;

- 1. ((**s**, a, e), (**s**, a))
- 2.((s, b, e), (s, b))
- 3. ((s, c, e), (f, e))
- 4. ((f, a, a), (f, e))
- 5. ((**f**, b, b), (**f**, e))

iki transition relation ((p, a, β), (q, y)) ve ((p, a', β'), (q', y'))
 compatible'dır (uyumludur) eğer a ve a' ile aynı zamanda β
 ve β' consistent ise yani her iki geçişin de aynı anda kabul edildiği bir durum varsa.

Her bir durum ve giriş sembolü için sadece bir geçiş vardır.

Örnek: $L = \{ww^R : w \in \{a, b\}^*\}$ dilini kabul eden aşağıdaki PDA nondeterministic'tir

$$M = (K, \Sigma, \Gamma, \Delta, s, F), K = \{s, f\}, \Sigma = \{a, b\}, \Gamma = \{a, b\}, F = \{f\}$$

∆ toplam 5 adet geçiş ilişkisine sahip olsun;

- 1. ((**s**, a, e), (**s**, a))
- 2. ((**s**, b, e), (**s**, b))
- 3. ((**s**, e, e), (**f**, e))
- 4. ((**f**, a, a), (**f**, e))
- 5. ((**f**, b, b), (**f**, e))

iki transition relation ((p, a, β), (q, y)) ve ((p, a', β'), (q', y'))
 compatible'dır (uyumludur) eğer a ve a' ile aynı zamanda β
 ve β' consistent ise yani her iki geçişin de aynı anda kabul edildiği bir durum varsa.

Transition 3, Transition 1 ve 2 ile compatible'dır. Ayrıca string'in orta noktası tahmin edilmektedir (belirgin değil).

- Deterministic context-free diller DPDA tarafından kabul edilir.
- Deterministic context-free diller giriş string'inin sonunu gösterebilmelidirler.
- $L \subseteq \sum^* deterministic\ context$ -free dildir eğer DPDA M için L\$ = L(M) ise.
- Burada \$ işareti string'in sonunu göstermektedir ve \$ ∉ ∑ olur.
- \$ işareti tüm string'lere otomatik olarak eklenmiştir.

```
Örnek: L = \{a^nb^n : n >= 0\} context-free dildir ve G = (\{a, b, S\}, \{a, b\}, R, S) grammar'i tarafından üretilir. R = (S \rightarrow e, S \rightarrow aSb) kurallarına sahiptir. Önce bir PDA oluşturalım. M_1 = (\{p, q\}, \{a, b\}, \{a, b, S\}, \Delta_1, p, \{q\}). L_1 = \{((p, e, e), (q, S)), ((q, e, S), (q, aSb)), ((q, e, S), (q, e)), ((q, a, a), (q, e)), ((q, b, b), (q, e))\}
```

 M_1 otomatı deterministic hale dönüştürülebilir ve L\$ dilini kabul eder.

$$M_2$$
=({p, q, q_a , q_b , q_s }, {a, b}, {a, b, S}, Δ_2 , p, { q_s })

Örnek: $L = \{a^nb^n : n >= 0\}$ context-free dildir ve $G = (\{a, b, S\}, \{a, b\}, R, S)$ grammar'i tarafından üretilir. $R = (S \rightarrow e, S \rightarrow aSb)$ kurallarına sahiptir. Önce bir PDA oluşturalım.

 $M_1 = (\{p, q\}, \{a, b\}, \{a, b, S\}, \Delta_1, p, \{q\}).$

 $L_1 = \{((p, e, e), (q, S)), ((q, e, S), (q, aSb)), ((q, e, S), (q, e)), ((q, a, a), (q, e)), ((q, b, b), (q, e))\}$

 M_1 otomatı deterministic hale dönüştürülebilir ve L\$ dilini kabul eder.

$$M_2$$
=({ p , q , q _{a} , q _{b} , q _{s} }, { a , b }, { a , b , S }, Δ $_2$, p , { q _{s} })

$$\Delta_{2} = \{ ((p, e, e), (q, S)), (1) \qquad ((q_{b}, e, b), (q, e)), \qquad (5)$$

$$((q, a, e), (q_{a}, e)), (2) \qquad ((q, \$, e), (q_{\$}, e)), \qquad (6)$$

$$((q_{a}, e, a), (q, e)), (3) \qquad ((q_{a}, e, S), (q_{a}, aSb)), \qquad (7)$$

$$((q, b, e), (q_{b}, e)), (4) \qquad ((q_{b}, e, S), (q_{b}, e)) \} \qquad (8)$$

 M_2 q durumundayken stack'ta işlem yapmadan girişten bir sembol okur ve q_a , q_b veya q_s durumlarından birisine geçer. Böylece compatible iki geçiş olan

((q, e, S), (q, aSb)) ve ((q, e, S), (q, e)) geçişlerini ayırır.

Top-Down Parsing $\Delta_2 = \{((p, e, e), (q, S)), (1)\}$

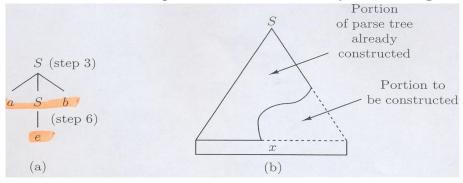
$$\Delta_{2} = \{ ((p, e, e), (q, S)), (1) \\ ((q_{b}, e, b), (q, e)), (2) \\ ((q, a, e), (q_{a}, e)), (2) \\ ((q_{a}, e, a), (q, e)), (3) \\ ((q_{a}, e, s), (q_{a}, e)), (4) \\ ((q_{b}, e, s), (q_{b}, e)), (4) \\ ((q_{b}, e, s), (q_{b}, e)), (8)$$

 \ddot{O} rnek : (devam) DPDA M_2 'nin ab\$ için geçişleri aşağıda verilmiştir.

Step	State	Unread Input	Stack	Transition Used	Rule of G
0	p	ab\$	е	_	
1	q	ab\$	S	1	
2	q_a	b\$	S	2	
3	q_a	b\$	aSb	7	$S \rightarrow aSb$
4	q	b\$	Sb	3	
5	q_b	\$	Sb	4	
6	q_b	\$	b	8	$S \rightarrow e$
7	q	\$	е	5	
8	$q_{\$}$	e	e	6	

Örnek : (devam)

- M_2 , $L = \{a^nb^n\}$ diline ait string'leri tanımak için deterministic olarak çalışır.
- M_2 giriş string'ini leftmost derivation ile üretir.
- Örnekteki 3. ve 6. adımlar parse tree'nin oluşturulduğu adımlardır.



- M_2 string'in dile ait olup olmadığını bulur, aynı anda parse tree oluşturur.
- Parse tree compiler'ların kullandıgı parser'larda assembly dilinde program oluşturmak için kullanılmaktadır.
- *M*₂ top-down parser'dır, parse tree top-down ve left-to-right yaklaşımıyla oluşur.

Örnek: Daha önce doğru yazılmış aritmetik ifadeler için oluşturulan grammar'e $F \to (E)$, şeklinde bir kural ekleyelim. Bu yeni kural fonksiyon çağırmalarını saglar.

```
(Orn.: sqrt(x * x + 1)) Bu grammar için bir top-down parser oluşturalım.
M_3 = (\{p, q\}, \sum, \Gamma, \Delta, p, \{q\}),
\sum = \{(,), +, *, id\},
T = L \cup \{E, T, F\}
L=0. ((p, e, e), (q, E))
  1. ((q, e, E), (q, E+T))
  2. ((q, e, E), (q, T))
  3.((q, e, T), (q, T*F))
  4. ((q, e, T), (q, F))
  5. ((q, e, F), (q, (E)))
  6. ((q, e, F), (q, id))
  7. ((q, e, F), (q, id(E)))
  8-12: ve son olarak tüm x \in \Sigma için ((q, x, x), (q, e)) \in \Delta olsun.
```

Örnek: (devam)

- Bu otomatta nondeterminism 1-2, 3-4 ve 5-6-7 kurallarından kaynaklanmaktadır.
- Transition 6 ve 7: M_3 otomatının (q, id, F) konfigürasyonunda olduğunu düşünelim. M_3 bu durumda 5, 6 veya 7 geçişlerinden birisini seçebilir. Input string'teki bir sonraki sembole (**id**) bakarak 5 elenir. Transition 5'te (**(**)bir sonraki semboldür. Ancak bir sonraki sembol 6 ve 7 için aynıdır (**id**).
- Bu problem sağ tarafı aynı olmasa da ilk sembolü aynı olan F → id ve F → id(E) kurallarından kaynaklanmaktadır.
- $F \rightarrow id$ ve $F \rightarrow id(E)$ kurallarının yerine $F \rightarrow idA$, $A \rightarrow e$ ve $A \rightarrow (E)$ kuralları konularak giderilebilir. Burada A yeni bir nonterminaldir.
- Transition 6 ve 7 yerine aşagıdaki kurallar konur;
- 6'. ((q, e, F), (q, idA)) 7'. ((q, e, A), (q, e)) 8'. ((q, e, A), (q, (E)))
- Geçişler $(q, id(id), F) \vdash_M (q, id(id), idA) \vdash_M (q, (id), A) \vdash_M (q, (id), (E)) \vdash_M ... olur.$

Nondeterminismi ortadan kaldırmak için kullanılan bu teknik **left factoring** olarak adlandırılır. Aşagıdaki kural ile özetlenebilir;

Heuristic Rule 1: Eğer

$$A \rightarrow \alpha \beta_1, A \rightarrow \alpha \beta_2, \ldots, A \rightarrow \alpha \beta_n$$

şeklinde kurallar varsa ve

 $\alpha \neq e \ ve \ n \geq 2 \ ise,$

bu kurallar

$$A \rightarrow \alpha A', A' \rightarrow \beta_i$$

kurallarıyla degiştirilir. A' yeni nonterminaldir.

Top-Down Parsing- Left Recursion

Transition 1 ve 2: Eğer M_3 otomatı bir sonraki input sembol için **id** görürse, ve stack'taki **E** ise birkaç farklı işlem yapılabilir. Transition 2 yapılarak E yerine T yazılır. Girişin sadece **id** olması durumunda bu geçerlidir.

Transition 1 kullanılarak E yerine E + T yazılır. Girişin **id + id** olması durumunda geçerlidir. Transition 1 iki defa ve Transition 1 bir defa kullanılabilir. Girişin **id + id + id** olması durumunda geçerlidir. Burada sağ taraftaki işlemin kaç defa tekrarlanacağının sınırı belli degildir.

- Bu olay **left recursion** olarak adlandırılır.
- Bu problem E→ E + T kuralından kaynaklanmaktadır. Soldaki nonterminal sağdaki ilk semboldür.
- $E \to E + T$ ve $E \to T$ kuralları yerine $E \to TE'$, $E' \to +TE'$ ve $E' \to e$ kuralları konularak giderilebilir. Burada E' yeni bir nonterminaldir.
- Aynı işlem $T \to T * F$, $T \to F$ içinde yapılır: $T \to FT'$, $T' \to *FT'$ ve $T' \to e$

Örnekteki grammar'in son şekli aşağıdaki gibi olur.

$$G' = (V', \sum, R', E),$$
 $V' = \sum \cup \{E, E', T, T', F, A\},$
 $R = 1. E \rightarrow TE'$
 $2. E' \rightarrow +TE'$

$$3.E' \rightarrow e$$

4.
$$T \rightarrow FT'$$

5.
$$T' \rightarrow *FT'$$

6.
$$T' \rightarrow e$$

7.
$$F \rightarrow (E)$$

8.
$$F \rightarrow idA$$

$$9. A \rightarrow e$$

10.
$$A \rightarrow (E)$$

Nondeterminismi ortadan kaldırmak için kullanılan bu left recursion teknigi aşagıdaki kural ile özetlenebilir;

Heuristic Rule 2: Eğer $A \rightarrow A\alpha_1,...,A \rightarrow A\alpha_n$ ve $A \rightarrow \beta_1,...,A \rightarrow \beta_m$ şeklinde kurallar varsa ve β_i ler A ile başlamıyorsa ve n > 0 ise, bu kurallar

$$A \rightarrow \beta_1 A', ..., A \rightarrow \beta_m A' \ ve \ A' \rightarrow \alpha_1 A', ..., A' \rightarrow \alpha_n A' \ ve \ A' \rightarrow e$$

kurallarıyla degiştirilir. A' yeni nonterminaldir.

Örnek: Önceki grammar'i tanıyan DPDA $M_4 = L(G')$ \$ oluşturalım.

```
M_4 = (K, \Sigma \cup \{\$\}, V', \Delta, p, \{q_\$\}),
K = \{p, q, q_{id}, q_{+}, q_{*}, q_{0}, q_{0}, q_{s}\},
\Delta = ((p, e, e), (q, E))
                                          tüm a \in \Sigma, \cup {$}
     ((q, a, e), (q_a, e))
     ((q_a, e, a), (q, e))
                                         tüm a \in \Sigma
     ((q_a, e, E), (q_a, TE'))
                                         tüm a \epsilon \sum \bigcup \{\$\}
     ((q_+, e, E'), (q_+, +TE'))
                                          tüm a \epsilon { ), \$ }
     ((q_a, e, E'), (q_a, e))
                                          tüm a \in \Sigma \cup \{\$\}
     ((q_a, e, T), (q_a, FT'))
     ((q_*, e, T'), (q_*, *FT'))
                                          t\ddot{u}m\ a\ \epsilon\ \{+,\}, \
     ((q_a, e, T'), (q_a, e))
     ((q_i, e, F), (q_i, (E)))
     ((q_{id}, e, F), (q_{id}, idA))
     ((q_i, e, A), (q_i, (E)))
                                          tüm a \in \{+, \cup, \}, \}
     ((q_a, e, A), (q_a, e))
```

 M_4 deterministic pushdown automaton'u G' grammar'i için bir parser'dır.

Örnek: (devam) id * (id)\$ giriş string'i aşağıdaki tabloda görüldüğü gibi kabul edilir.

Step	State	Unread Input	Stack	Rule of G'
0	p	id * (id)\$	e	
1	q	id*(id)\$	E	
2	q_{id}	*(id)\$	E	
3	q_{id}	*(id)\$	TE'	1
4	q_{id}	*(id)\$	FT'E'	4
5	q_{id}	*(id)\$	idAT'E'	8
6	q	*(id)\$	AT'E'	
7	q_*	(id)\$	AT'E'	
8	q_*	(id)\$	T'E'	9
9	q_*	(id)\$	*FT'E'	5
10	q	(id)\$	FT'E'	
11	$q_{(}$	id)\$	FT'E'	
12	$q_{(}$	id)\$	(E)T'E'	7
13	\dot{q}	id)\$	E)T'E'	

Örnek: (devam)

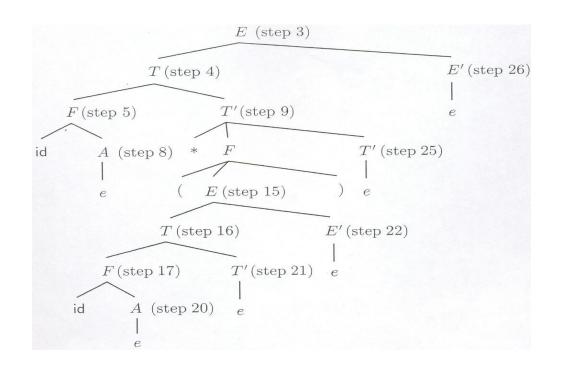
14	$q_{\sf id}$)\$	E)T'E'	
15	q_{id})\$	TE')T'E'	1
16	$q_{\sf id}$)\$	FT'E')T'E'	4
17	$q_{\sf id}$)\$	idAT'E')T'E'	8
18	q)\$	AT'E')T'E'	
19	$q_{)}$	\$	AT'E')T'E'	
20	$q_{)}$	\$	T'E')T'E'	. 10
21	$q_{)}$	\$	E')T'E'	6
22	$q_{)}$	\$)T'E'	3
23	q	\$	T'E'	6
24	$q_\$$	e	T'E'	
25	$q_{\$}$	e	E'	6
26	$q_{\$}$	e	e	3

Örnek: (devam) G' deki kurallar ile stack üzerinde nonterminal degi\$tirilen adımlar tabloda son sütunda numaralandırılmı\$tır. Sırayla bu kurallar uygulandıgında id*(id)\$ string'inin leftmost derivation'ı elde edilir.

Oluşturulan parse yandadır.

```
E \Rightarrow TE'
```

- $\Rightarrow FT'E'$
- $\Rightarrow idT'E'$
- $\Rightarrow id *FT'E'$
- $\Rightarrow id *(E)T'E'$
- \Rightarrow id *(TE')T'E'
- \Rightarrow id *(FT'E')T'E'
- $\Rightarrow id *(idT'E')T'E'$
- \Rightarrow id *(idE')T'E'
- \Rightarrow id *(id)T'E'
- \Rightarrow id *(id)E'
- \Rightarrow id *(id)



Parse tree **top-down** ve **left-first** olarak oluşmuştur.

- Context-free dillerin parse edilmesinde en iyi yol yoktur. Farklı grammar'ler için farklı yöntemler vardır.
- Farklı bir yaklaşımda automaton ilk önce girişi okur ve derivation sonra yapılır.
- Sonuçta parse tree yapraklardan root node'a dogru gerçekleşir.
- Bu yöntemler **bottom-up** olarak adlandırılırlar.

G = (V, L, R, S) bir CFG için $M = (K, \sum, \Gamma, \Delta, p, F)$ bottom-up pushdown automaton'u oluşturalım. Burada $K = \{p, q\}, \Gamma = V, F = \{q\}$ ve Δ aşağıdaki geçişlere sahip olsun.

- 1. ((p, a, e), (p, a)) tüm $a \in L$ için
- 2. $((p, a, \alpha^R), (p, A))$ $t \ddot{u} m A \rightarrow \alpha \in R i \varsigma i n$
- *3.* ((*p*, *e*, *S*), (*q*, *e*))

Her transition bir transition sınıfını göstermektedir. Transition 1 input sembolleri stack'a aktarır. Transition 2 stack'ta kuralların sag kısmının yerine sol kısmını degiştirir.

Kuralların sag kısmı ters sırada bulunmalıdır. Transition 3 ise sonuç durumuna geçerek çalışmayı sonlandırmayı saglar.

Örnek: Aritmetik deyimleri üreten gramer için bir bottom-up pushdown automaton oluşturalım. Kurallar aşağıdaki gibi olsun.

$$E \rightarrow E + T$$
 (R1)

$$E \rightarrow T$$

$$T \rightarrow T * F$$
 (R3)

$$T \rightarrow F$$

$$F \rightarrow (E)$$
 (R5)

$$F \rightarrow id$$

M pushdown automaton'u için aşagıdaki geçişler oluşturulur.

$$(p, a, e), (p, a)$$
 $t \ddot{u} m \ a \in \sum i \dot{c} i n$

$$(\Delta 0)$$

$$(p, e, T + E), (p, E)$$

$$(\Delta 1)$$

$$(\Delta 2)$$

$$(p, e, F * T), (p, T)$$

$$(\Delta 3)$$

$$(\Delta 4)$$

$$(\Delta 5)$$

$$(\Delta 6)$$

$$(\Delta 7)$$

Örnek: (devam) id * (id) aşagıdaki gibi kabul edilir.

Step	State	Unread Input	Stack	Transition Used	Rule of G
0	p	id*(id)	e		
1	p	*(id)	id	$\Delta 0$	
2	p	*(id)	F	$\Delta 6$	R6
3	p	*(id)	T	$\Delta 4$	R4
4	p	(id)	*T	$\Delta 0$	
5	p	id)	(*T	$\Delta 0$	
6	p)	id(*T	$\Delta 0$	
7	p)	F(*T	$\Delta 6$	R6
8	p)	T(*T	$\Delta 4$	R4
9	p)	E(*T	$\Delta 2$	R2
10	p	e)E(*T	$\Delta 0$	
11	p	e	F * T	$\Delta 5$	R5
12	p	e	T	$\Delta 3$	R3
13	p	e	E	$\Delta 2$	R2
14	q	e	e	$\Delta 7$	

Örnek: (devam)

- M otomatı deterministic degildir. Çünkü △0 diğer tüm geçişlerle (△ 1 △ 8) compatible'dir.
- Herhangi bir anda M bir terminali stack'a aktarabilir (1, 4, 5, 6 ve 10 adımlar) veya stack'taki birkaç sembolü bir kuralın sag kısmı olarak elde edebilir.
- Kuralın sağ kısmı olarak görülen string sol kısımla değiştirilerek indirgenir (△1 –△6).
- indirgeme yapılan adımlar ters sırada alınırsa rightmost derivation yapılır.

Örnek: (devam)

indirgeme yapılan adımların ters sırada alınmasıyla elde edilen rightmost derivation aşagıdaki gibidir.

$$E \Rightarrow T$$

$$\Rightarrow T * F$$

$$\Rightarrow T * (E)$$

$$\Rightarrow T * (T)$$

$$\Rightarrow T * (F)$$

$$\Rightarrow T * (id)$$

$$\Rightarrow F * (id)$$

$$\Rightarrow$$
 id * (id)

Ödev

■ Problemleri çözünüz 3.7.1a, 3.7.1b (sayfa 173)